

Laboratorium 4: Kodowanie znaków w komputerze

Opracowanie zestawu zadań (część programistyczna)

Kacper Bednarczuk

Zadanie 2: Zapis i analiza plików

Kod programu

```
const fs = require("fs"); // Wbudowany moduł do operacji na systemie plików
const iconv = require("iconv-lite"); // Biblioteka do konwersji kodowań w
Node.js

const text = "Język: polski (żółć)";


// 1. Zapis do pliku tekst_utf8.txt (UTF-8)
fs.writeFileSync("tekst_utf8.txt", text, "utf8");
console.log("Zapisano tekst_utf8.txt");

// 2. Zapis do pliku tekst_iso.txt (ISO-8859-2)
const isoBuffer = iconv.encode(text, "iso-8859-2");
fs.writeFileSync("tekst_iso.txt", isoBuffer);
console.log("Zapisano tekst_iso.txt");

// 3. Zapis do pliku tekst_ascii.txt (ASCII)
const asciiBuffer = iconv.encode(text, "ascii"); // Konwersja z zastąpieniem
nieobsługiwanych znaków na '?'
fs.writeFileSync("tekst_ascii.txt", asciiBuffer);
console.log("Zapisano tekst_ascii.txt");
```

Analiza plików w edytorze HEX

tekst_ascii.txt



4A 3F 7A 79 6B 3A 20 70 6F 6C 73 6B 69 20 28 3F
3F 3F 3F 29 +

tekst_iso.txt

```
4A EA 7A 79 6B 3A 20 70 6F 6C 73 6B 69 20 28 BF
F3 B3 E6 29 +
```

tekst_utf8.txt

```
4A C4 99 7A 79 6B 3A 20 70 6F 6C 73 6B 69 20 28
C5 BC C3 B3 C5 82 C4 87 29 +
```

Odpowiedzi na pytania

1. Jak wygląda zawartość pliku tekst_ascii.txt ? Co stało się z polskimi znakami?

Zawartość pliku tekst_ascii.txt to Język: polski (????). Wszystkie polskie znaki diakrytyczne (ę , ż , ó , ł , ć) zostały zastąpione znakami zapytania (?). Stało się tak, ponieważ kodowanie ASCII nie posiada reprezentacji dla tych znaków, a zastosowany w kodzie moduł zastępuje każdy nieobsługiwany znak znakiem ? .

2. Porównaj rozmiar (w bajtach) plików tekst_iso.txt i tekst_utf8.txt . Który jest większy i dlaczego?

```
tekst_ascii.txt      20
tekst_iso.txt        20
tekst_utf8.txt       25
```

- Rozmiar tekst_iso.txt : **20 bajtów**
- Rozmiar tekst_utf8.txt : **25 bajtów**

Plik tekst_utf8.txt jest większy. Przyczyną jest sposób, w jaki UTF-8 koduje znaki spoza podstawowego zestawu ASCII. W kodowaniu ISO-8859-2 każdy znak (zarówno standardowy, jak i polski) jest reprezentowany przez **jeden bajt**. Natomiast w UTF-8 znaki polskie (ę , ż , ó , ł , ć) są kodowane za pomocą **dwóch bajtów**. W analizowanym tekście znajduje się 5 polskich znaków, co prowadzi do różnicy w rozmiarze pliku.

3. Wskaż w widoku HEX pliku tekst_utf8.txt sekwencje bajtów odpowiadające znakom ż , ó i ł . Czy zgadzają się one z Twoimi ręcznymi obliczeniami z części 1?

Tak, sekwencje bajtów zgadzają się z obliczeniami z części teoretycznej:

- ż jest reprezentowane przez sekwencję C5 BC .
- ó jest reprezentowane przez sekwencję C3 B3 .
- ł jest reprezentowane przez sekwencję C5 82 .

Wszystkie te wartości można odnaleźć w zrzucie ekranu z edytora heksadecymalnego dla pliku tekst_utf8.txt .